Verifying Transactional Consistency of MongoDB

(submitted to VLDB'2022)

Hengfeng Wei

hfwei@nju.edu.cn

December 27, 2021


mongoDB

MongoDB 的三种经典部署架构

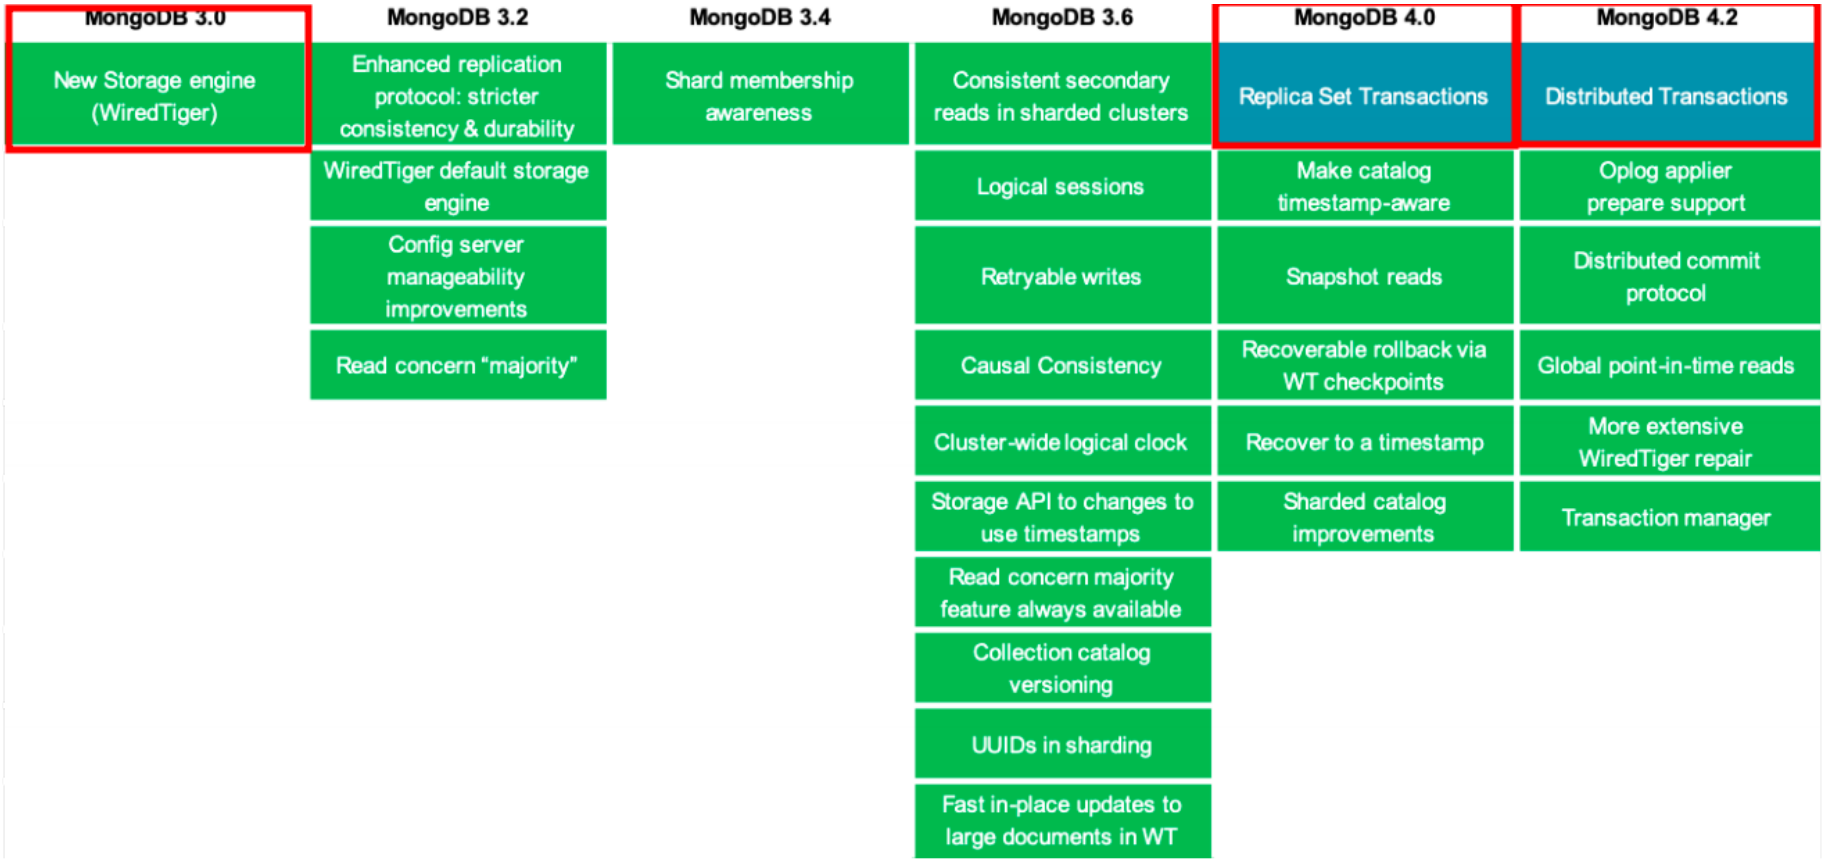

MongoDB 事务的三阶段发展过程

A Fundamental Question:

What transactional consistency guarantee do MongoDB transactions in each deployment provide?

挑战一：MongoDB 官方规约不清楚, SI 有多种变体

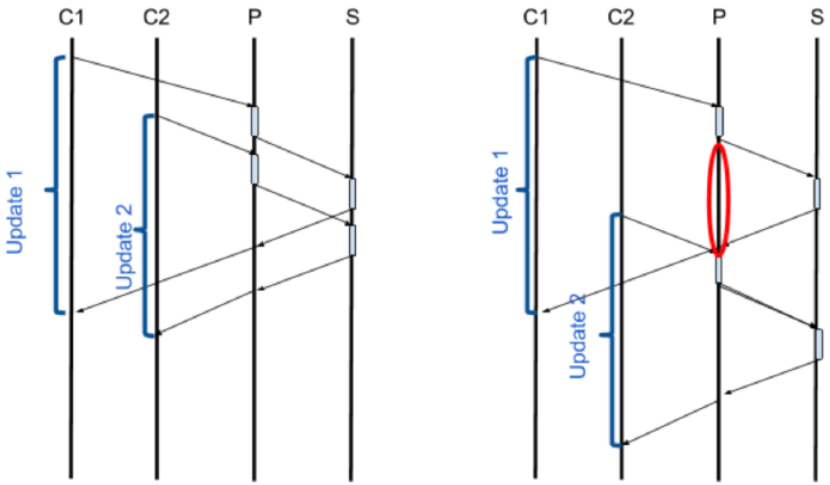

Figure 3: Back-to-Back Transactions with and without Speculative Snapshot Isolation

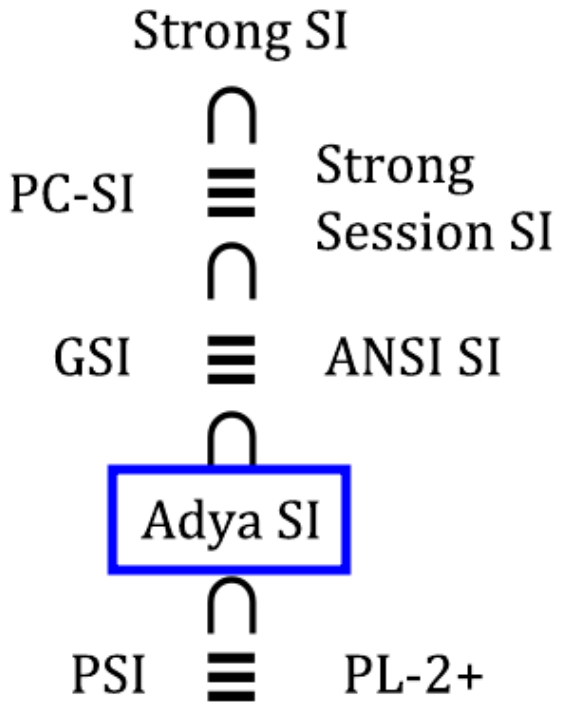

挑战二：MongoDB 缺少精简的事务协议描述，更没有严格证明

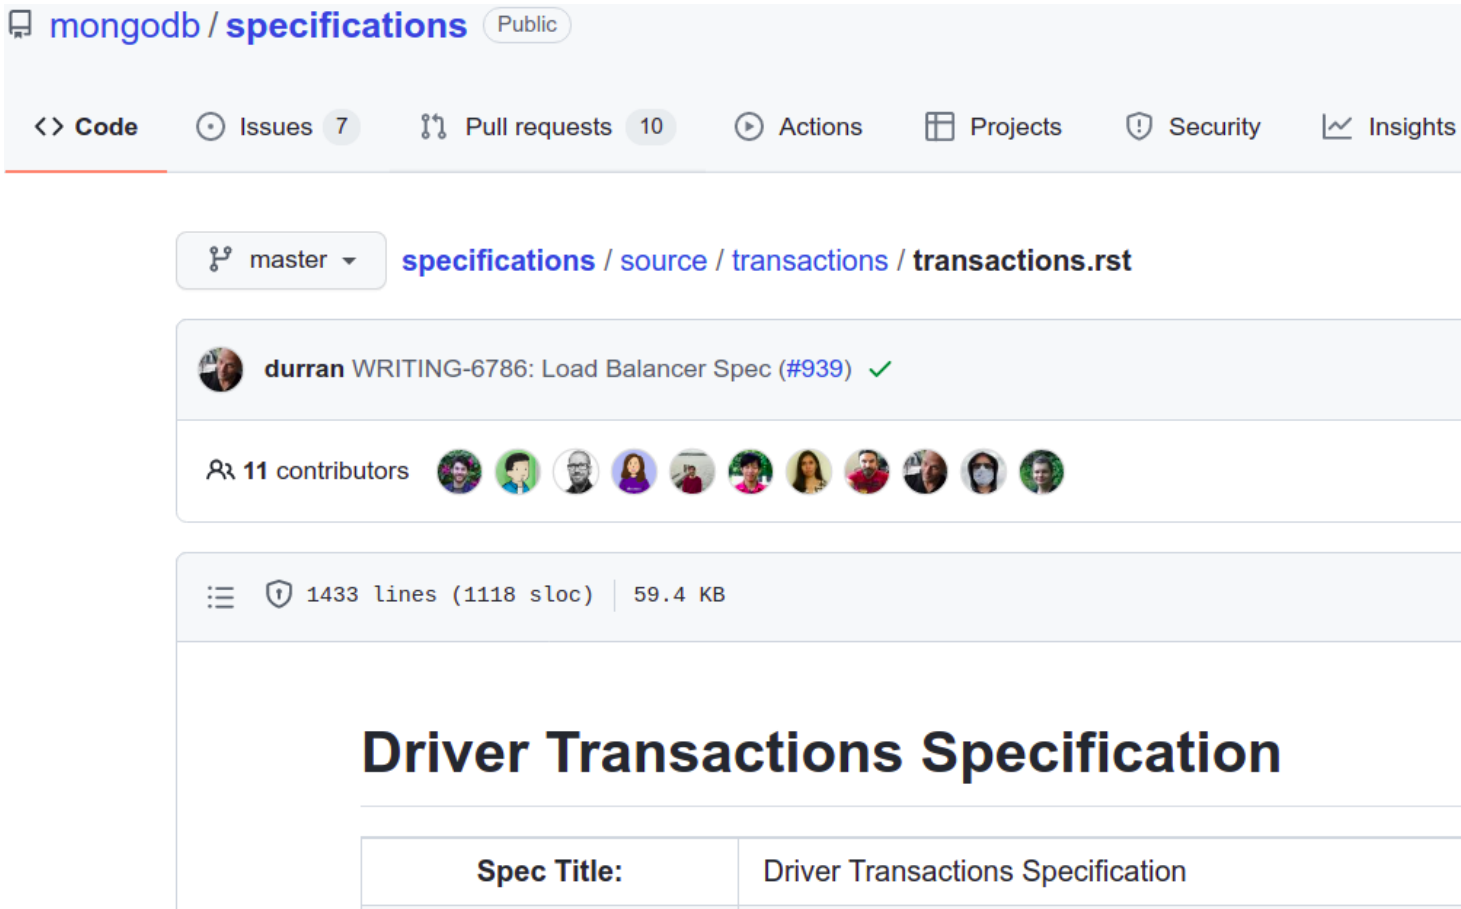

挑战三: SI 检测问题是 NP-complete 问题, 复杂度高

THEOREM 3.2. *For any criterion* $C \in \{$PREFIX CONSISTENCY, SNAPSHOT ISOLATION, SERIALIZABILITY$\}$ *the problem of checking whether a given history satisfies* C *is NP-complete.*

贡献一: 使用 (VIS, AR) 框架, 为多种 SI 变体提供形式化规约

贡献二：为 MongoDB 事务一致性协议提供精简的伪代码描述

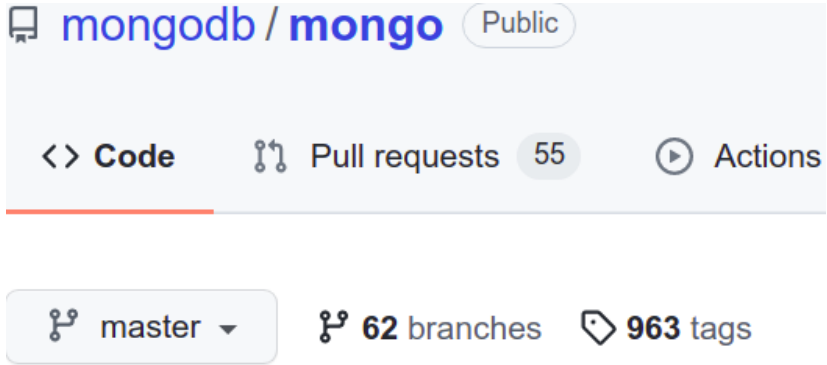

贡献三: 证明 WiredTiger、ReplicaSet、ShardedCluster 事务协议分别满足 StrongSI、RealtimeSI、SessionSI 变体

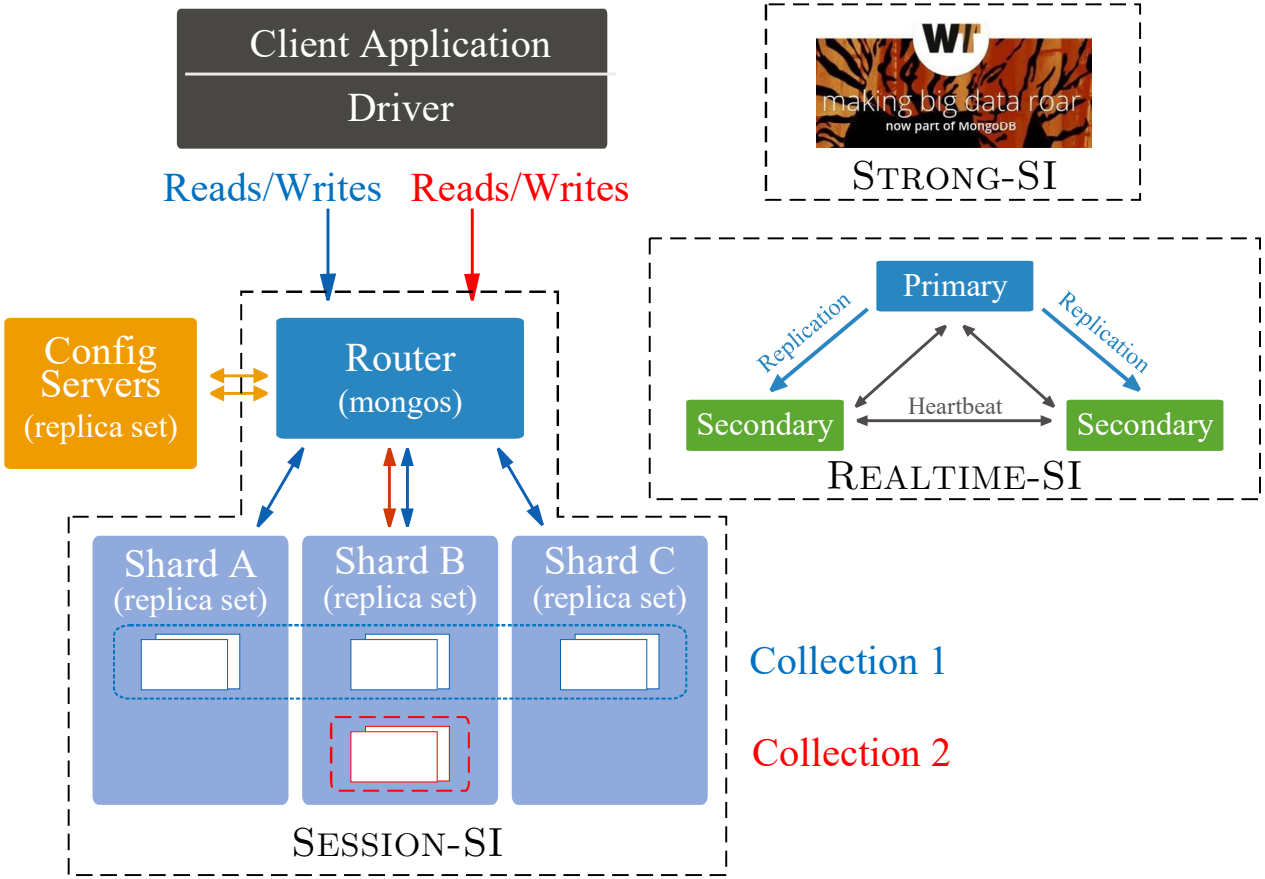

贡献四：设计并评估了多项式时间 SI 变体白盒检测算法

1. 事务 $T : (E, \mathsf{po})$
   - po : Program Order
   - $start(T)$: 事务开始时间
   - $commit(T)$: 事务提交时间

2. 历史 $\mathcal{H} : (\mathbb{T}, \mathrm{SO})$
   - $\mathbb{T}$: 已提交事务集合
   - SO : Session Order

3. 执行 $\mathcal{A} : (\mathcal{H}, \mathrm{VIS}, \mathrm{AR})$
   - VIS : 可见性 (Visibility) 偏序关系
   - AR : 仲裁 (Arbitration) 全序关系
   - $\mathrm{VIS} \subseteq \mathrm{AR}$

一个事务一致性模型可定义为一组一致性公理的集合 Φ。

历史 $\mathcal{H}$ 满足事务一致性模型 Φ, 如果存在 VIS 与 AR 使得

$$\exists \mathrm{VIS}, \mathrm{AR}.\ (\mathcal{H}, \mathrm{VIS}, \mathrm{AR}) \models \Phi。$$

$$\forall (E, \mathsf{po}) \in \mathcal{H}.\ \forall e \in \mathsf{Event}.\ \forall key, val.\ \big(\mathsf{op}(e) = \mathsf{read}(key, val) \wedge \{f \mid (\mathsf{op}(f) = \_(key, \_) \wedge f \xrightarrow{\mathsf{po}} e\} \neq \emptyset\big) \implies \mathsf{op}(\max_{\mathsf{po}}\{f \mid \mathsf{op}(f) = \_(key, \_) \wedge f \xrightarrow{\mathsf{po}} e\}) = \_(key, val) \quad \text{(Int)}$$

$$\forall T \in \mathcal{H}.\ \forall key, val.\ T \vdash \mathsf{read}(key, val) \implies \max_{\mathrm{AR}}(\mathrm{VIS}^{-1}(T) \cap \mathsf{WriteTx}_{key}) \vdash \mathsf{write}(key, val) \quad \text{(Ext)}$$

$\mathrm{SO} \subseteq \mathrm{VIS}$ (Session)	$\mathrm{AR}\ ;\mathrm{VIS} \subseteq \mathrm{VIS}$ (Prefix)
$\mathrm{RB} \subseteq \mathrm{VIS}$ (ReturnBefore)	$\mathrm{CB} \subseteq \mathrm{AR}$ (CommitBefore)
$\mathrm{VIS} \subseteq \mathrm{RB}$ (RealtimeSnapshot)	$\forall S, T \in \mathcal{H}.\ S \bowtie T \implies (S \xrightarrow{\mathrm{VIS}} T \vee T \xrightarrow{\mathrm{VIS}} S)$ (NoConflict)

$$\text{SI} = \textsc{Int} \wedge \textsc{Ext} \wedge \textsc{Prefix} \wedge \textsc{NoConflict}$$

$$\textsc{SessionSI} = \text{SI} \wedge \textsc{Session}$$

$$\textsc{SessionSI} = \text{SI} \wedge \textsc{Session}$$

$$\textsc{RealtimeSI} = \text{SI} \wedge \textsc{ReturnBefore} \wedge \textsc{CommitBefore}$$

$$\textsc{SessionSI} = \text{SI} \wedge \textsc{Session}$$

$$\textsc{RealtimeSI} = \text{SI} \wedge \textsc{ReturnBefore} \wedge \textsc{CommitBefore}$$

$$\text{GSI} = \text{SI} \wedge \textsc{RealtimeSI} \wedge \textsc{CommitBefore}$$

$$\textsc{SessionSI} = \text{SI} \wedge \textsc{Session}$$

$$\textsc{RealtimeSI} = \text{SI} \wedge \textsc{ReturnBefore} \wedge \textsc{CommitBefore}$$

$$\text{GSI} = \text{SI} \wedge \textsc{RealtimeSI} \wedge \textsc{CommitBefore}$$

$$\textsc{StrongSI} = \text{GSI} \wedge \textsc{ReturnBefore}$$

- ANSI-SI
- SI
- GSI
- StrongSI
- StrongSessionSI
- PSI
- WriteSI
- NMSI
- PCSI

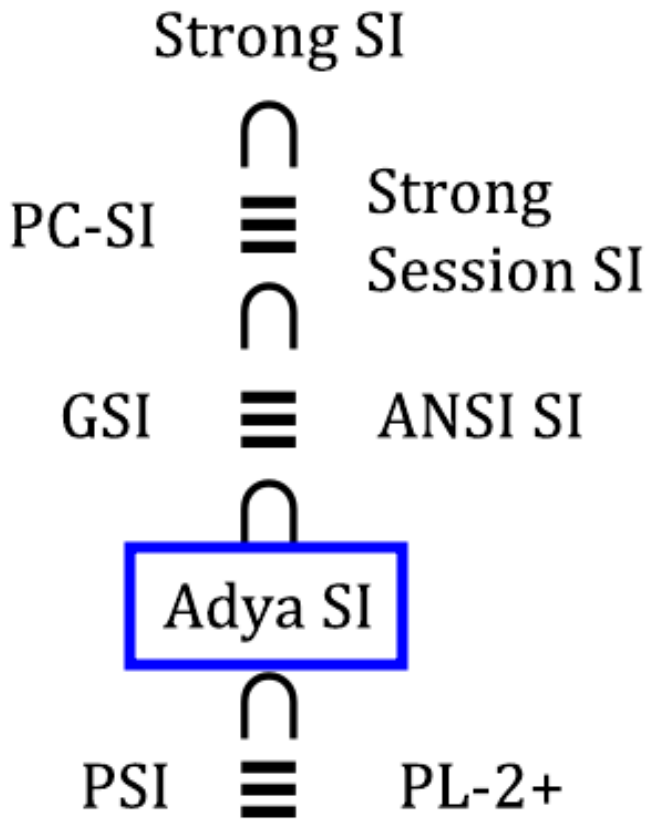

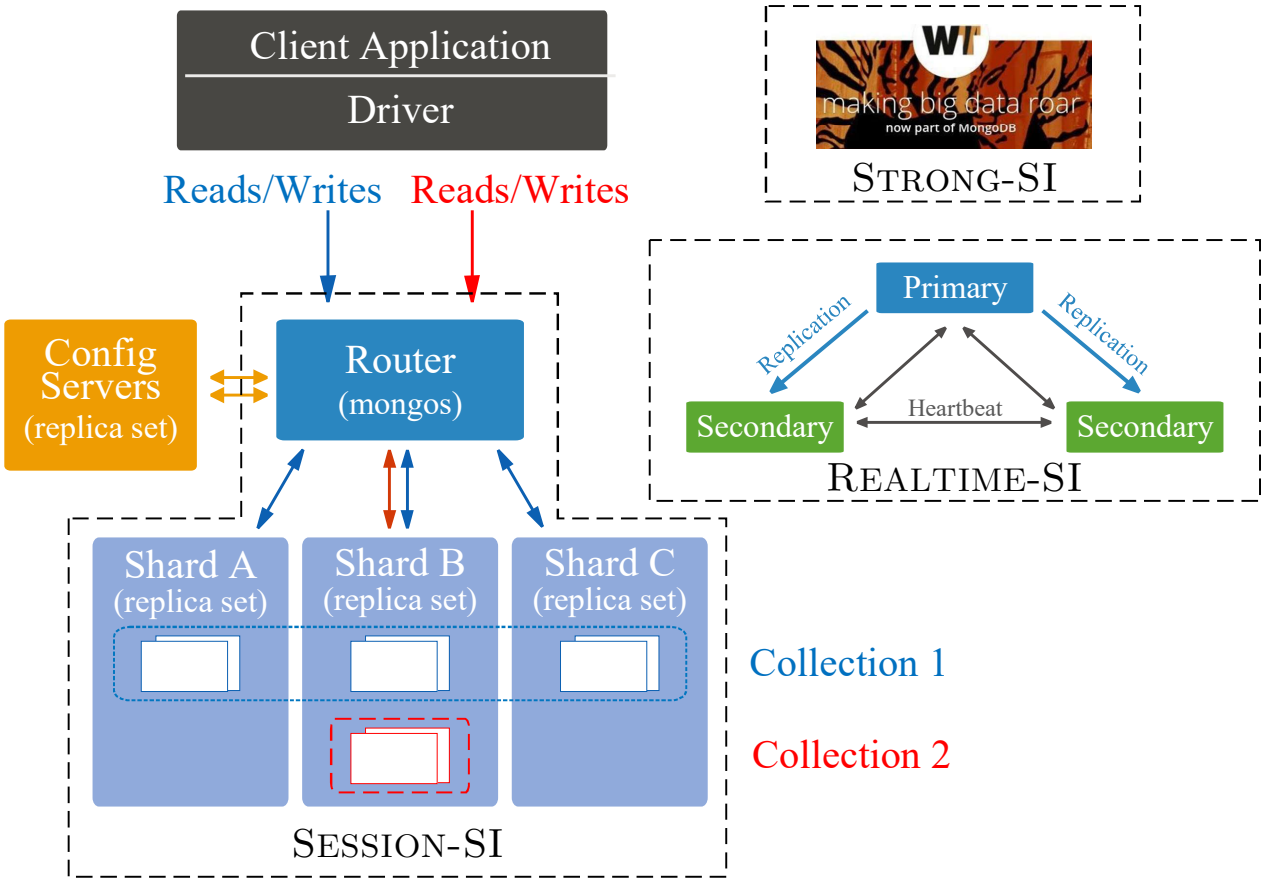

重点在于如何确定每个事务的“读快照” (Read Snapshot),

也就是对该事务可见的所有事务构成的集合

$\textsc{WiredTiger} \models \textsc{StrongSI}$

每个 WiredTiger 事务 $txn \in \mathsf{WT\_TXN}$ 有一个唯一标识号

$$txn.\mathsf{tid} \in \mathsf{TID} = \mathbb{N} \cup \{-1, \bot_{\mathsf{tid}}\}$$

- 事务开始时 (WT_START), $txn.\mathsf{tid} = 0$
- 事务第一个写操作成功执行后 (WT_UPDATE), $txn.\mathsf{tid} > 0$
- 事务因写冲突回滚时 (WT_ROLLBACK), $txn.\mathsf{tid} = -1$

每个 WiredTiger 事务 $txn \in \mathsf{WT\_TXN}$ 有一个唯一标识号

$$txn.\mathsf{tid} \in \mathsf{TID} = \mathbb{N} \cup \{-1, \bot_{\mathsf{tid}}\}$$

- 事务开始时 (WT_START), $txn.\mathsf{tid} = 0$
- 事务第一个写操作成功执行后 (WT_UPDATE), $txn.\mathsf{tid} > 0$
- 事务因写冲突回滚时 (WT_ROLLBACK), $txn.\mathsf{tid} = -1$
- $\bot_{\mathsf{tid}}$ 表示不存在这个事务

每个 WiredTiger 事务 $txn \in \mathsf{WT\_TXN}$ 有一个唯一标识号

$$txn.\mathsf{tid} \in \mathsf{TID} = \mathbb{N} \cup \{-1, \bot_{\mathsf{tid}}\}$$

- 事务开始时 (WT_START), $txn.\mathsf{tid} = 0$
- 事务第一个写操作成功执行后 (WT_UPDATE), $txn.\mathsf{tid} > 0$
- 事务因写冲突回滚时 (WT_ROLLBACK), $txn.\mathsf{tid} = -1$
- $\bot_{\mathsf{tid}}$ 表示不存在这个事务

对于只读事务 txn, 始终有 $txn.\mathsf{tid} = 0$

- 客户端通过会话 (Session) 与 WiredTiger 进行交互
- 每个会话有一个唯一会话标识号 $wt\_sid \in \mathsf{WT\_SID} = \mathbb{N}$

- 客户端通过会话 (Session) 与 WiredTiger 进行交互
- 每个会话有一个唯一会话标识号 $wt\_sid \in \mathsf{WT\_SID} = \mathbb{N}$
- WiredTiger 维护数据结构
  $\mathsf{wt\_txn\_global} \in [\mathsf{current\_tid} : \mathsf{TID}, \mathsf{states} : \mathsf{WT\_SID} \to \mathsf{TID}]$

  current_tid : 当前分配的最大事务标识号

  states : 会话与会话之上当前事务之间的映射关系

- 客户端通过会话 (Session) 与 WiredTiger 进行交互
- 每个会话有一个唯一会话标识号 $wt\_sid \in \mathsf{WT\_SID} = \mathbb{N}$
- WiredTiger 维护数据结构
  $\mathsf{wt\_txn\_global} \in [\mathsf{current\_tid} : \mathsf{TID}, \mathsf{states} : \mathsf{WT\_SID} \to \mathsf{TID}]$

  current_tid : 当前分配的最大事务标识号

  states : 会话与会话之上当前事务之间的映射关系

  事务 txn 提交或回滚时, $\mathsf{wt\_txn\_global.states}[wt\_sid] \leftarrow \perp_{\mathsf{txn}}$

每个事务只能观察到在它开始之前提交的事务

$$\textsc{WiredTiger} \models \textsc{RealtimeSI}$$

每个事务只能观察到在它开始之前提交的事务

$\textsc{WiredTiger} \models \textsc{RealtimeSI}$

每个事务在开始时 (WT_START) 根据
wt_txn_global 维护的信息确定它的 “读快照”

WiredTiger 事务协议从反面入手计算, 排除不可见事务集合

每个事务 txn 维护以下信息:

txn.snapshot : 正在进行的、已获取事务标识号的事务集合

txn.snap_max : txn 开始时, 当前最大的事务标识号

$$\mathsf{wt\_txn\_global} \in [\mathsf{current\_tid} : \mathsf{TID}, \mathsf{states} : \mathsf{WT\_SID} \to \mathsf{TID}]$$

1: **procedure** TXN_VISIBLE(txn, tid)
2: **return** $\neg\big(tid = -1 \vee tid \in txn.\text{snapshot} \vee (tid \geq txn.\text{snap\_max} \wedge tid \neq txn.\text{tid})\big)$

对于事务 txn, 满足以下条件的、标识号等于 tid 的事务对 txn 不可见:

- $tid = -1$: 该事务已回滚
- $tid \in txn.snapshot$: 该事务与 txn 并发
- $\text{tid} \geq txn.\text{snapshot} \wedge \text{tid} \neq txn.\text{tid}$:
  - $\text{tid} \geq txn.\text{snapshot}$: 该事务开始得比 txn 晚
  - $\text{tid} \neq txn.\text{tid}$: 允许 txn 观察到自身

每个事务观察到在它开始之前提交的事务

Definition (Visibility Relation)

$$\text{VIS}_{\text{WT}} \triangleq \text{RETURNBEFORE}.$$

在逻辑上, 所有事务按实时序依次提交

Definition (Arbitration Relation)

$$\text{AR}_{\text{WT}} \triangleq \text{COMMITBEFORE}.$$

Lemma (冲突事务的提交顺序)

$$\forall txn, txn' \in \mathsf{WT\_TXN}.$$

$$txn \bowtie txn' \implies (txn \xrightarrow{AR_{WT}} txn' \iff txn.\mathsf{tid} < txn'.\mathsf{tid}).$$

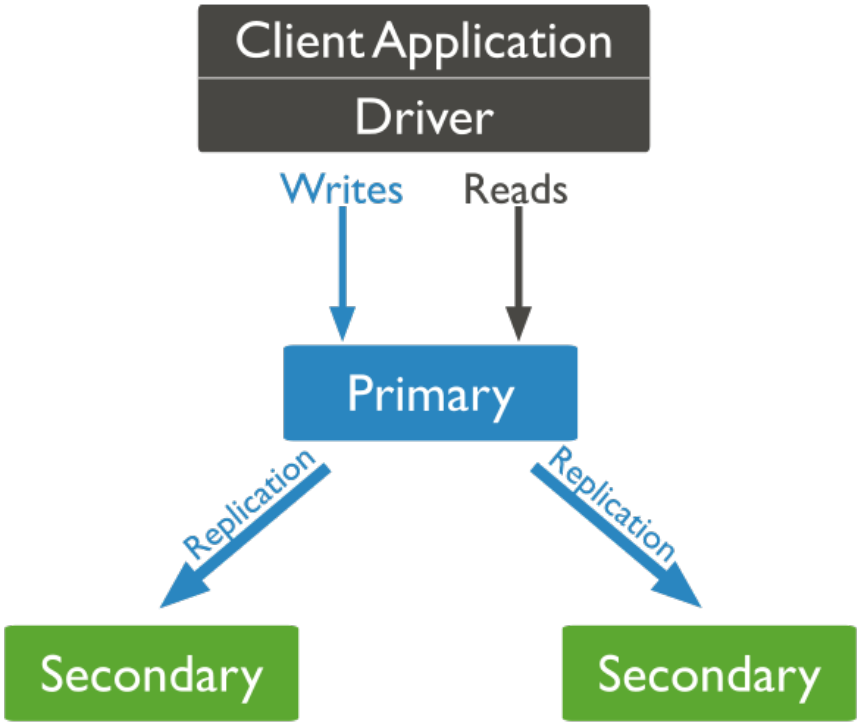

$\textsc{ReplicaSet} \models \textsc{RealtimeSI}$

Conclusion

Hengfeng Wei (hfwei@nju.edu.cn)